

Introducere in Machine Learning

Un curs scurt pentru testarea unei aplicatii RAG

Capitolul 1: Ce este Machine Learning

Machine Learning (ML) este o ramura a inteligentei artificiale care permite calculatoarelor sa invete din date, fara sa fie programate explicit pentru fiecare sarcina in parte. In loc sa scriem reguli fixe de tipul "daca X, atunci Y", oferim algoritmului multe exemple, iar el descopera singur tiparele din date.

Exista trei categorii principale de invatare automata: invatarea supervizata, invatarea nesupervizata si invatarea prin recompensa (reinforcement learning). Fiecare categorie este potrivita pentru tipuri diferite de probleme.

1.1 Invatarea supervizata

In invatarea supervizata, algoritmul primeste date etichetate — adica pentru fiecare exemplu de antrenament exista deja raspunsul corect. De exemplu, un model care recunoaste pisici in poze este antrenat cu mii de imagini, fiecare avand eticheta "pisica" sau "nu este pisica". Scopul modelului este sa invete sa generalizeze, astfel incat sa recunoasca pisici si in imagini noi, pe care nu le-a mai vazut.

Doua sarcini comune in invatarea supervizata sunt clasificarea (predictia unei categorii, ca in exemplul cu pisicile) si regresia (predictia unei valori numerice, de exemplu pretul unei case pe baza suprafetei si a locatiei).

1.2 Invatarea nesupervizata

Aici algoritmul primeste date fara etichete si trebuie sa descopere singur structuri sau tipare ascunse. Un exemplu tipic este clustering-ul: gruparea clientilor unui magazin in functie de comportamentul de cumparare, fara sa stim dinainte cate grupuri exista sau ce caracteristici au.

Capitolul 2: Retele neuronale

O retea neuronală este un model matematic inspirat, foarte vag, de modul in care functioneaza neuronii biologici. Este formata din straturi de "noduri" (numite neuroni artificiali), conectate intre ele prin ponderi numerice.

Datele intra prin stratul de intrare, trec prin unul sau mai multe straturi ascunse, unde sunt transformate repetat prin inmultiri si functii de activare, si ies prin stratul de iesire ca o predictie finala.

2.1 Antrenarea unei rețele

Antrenarea înseamnă ajustarea treptată a ponderilor rețelei, astfel încât predicțiile ei să se apropie tot mai mult de răspunsurile corecte. Acest proces folosește doi pași repetati de multe ori: propagarea înainte (forward pass), în care datele trec prin rețea și generează o predicție, și propagarea înapoi (backpropagation), în care eroarea dintre predicție și răspunsul corect este folosită pentru a corecta ponderile.

Un optimizator popular pentru acest proces este Adam, care ajustează automat rata de învățare pentru fiecare pondere în parte, ceea ce duce de obicei la o antrenare mai rapidă și mai stabilă decât metodele clasice de gradient descent.

Capitolul 3: Embeddings și căutare semantică

Un embedding este o reprezentare numerică a unei bucăți de text (un cuvânt, o propoziție sau un paragraf) sub forma unui vector — un sir de numere. Textele cu înțeles similar au vectori apropiați unii de alții în acest spațiu numeric, chiar dacă folosesc cuvinte diferite.

Această proprietate permite căutarea semantică: în loc să căutăm potrivirea exactă a unor cuvinte, căutăm texte al căror înțeles este apropiat de întrebarea pusă, comparând vectorii lor. Distanța dintre doi vectori este de obicei măsurată prin similaritatea cosinus, care indică cât de apropiate sunt direcțiile celor doi vectori în spațiu.

3.1 RAG (Retrieval-Augmented Generation)

RAG este o arhitectură în care un model de limbaj (LLM) nu răspunde doar din memoria acumulată la antrenare, ci primește și un context relevant, extras dintr-o bază de date externă, chiar înainte de a genera răspunsul. Pașii tipici sunt: împărțirea documentelor în bucăți mici (chunking), transformarea fiecărei bucăți într-un embedding, stocarea lor într-o bază de date vectorială, căutarea celor mai relevante bucăți pentru o întrebare, și trimiterea lor către LLM împreună cu întrebarea.

Avantajul principal al RAG este că modelul poate răspunde corect despre informații pe care nu le-a văzut niciodată în timpul antrenării, de exemplu conținutul unui document încărcat chiar de utilizator.